IVNEX v69

Кернелы для LoRA на бесплатной T4



Soup Kernel Challenge · Decentrathon 6.0

Qwen2.5-1.5B-Instruct / Soup 0.77.0

Нұржігіт Мерей Владимир Анаис

Фиксированная задача

14 345 MiB

пик памяти базового Soup

82,14 с

полная команда обучения

Модель

Qwen2.5-1.5B-Instruct

Адаптация

NF4, LoRA r=16 / q_proj + v_proj

Данные

256 казахских инструкций

Обучение

batch 4 / seq ≤512 / 64 шага

Платформа

одна Tesla T4, FP16

Обработка внутри исходного батча

Исходный батч



Реальные токены



Padding

Границы строк, позиции и маски сохраняются

Схема упаковки. Строки между батчами не смешиваем.

Кернелы и память

01 **Fused RMSNorm + residual**

Меньше промежуточных тензоров и запусков

02 **NF4 и LoRA rematerialization**

Восстановление входа в backward, кеш ≤64 MiB

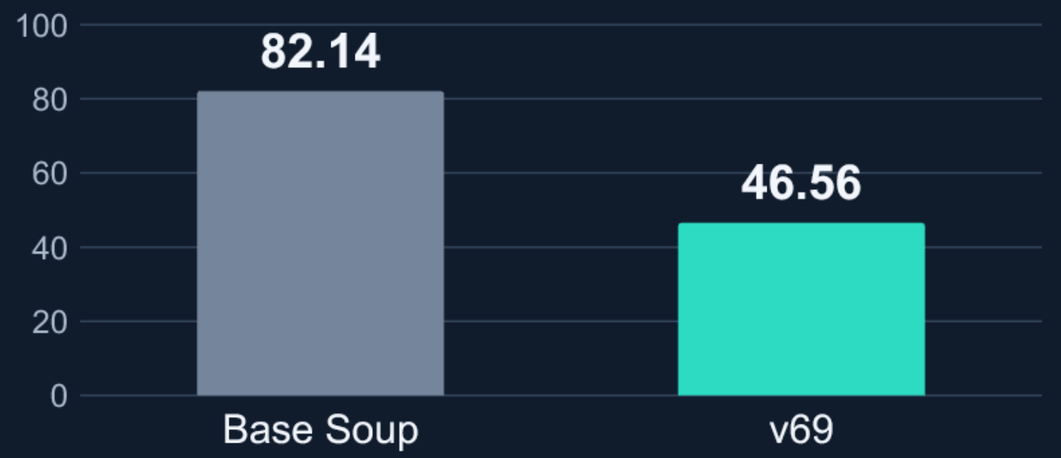
03 **Chunked LM-head**

Весь словарь, entropy, accuracy и rewind

14,4% времени обучения занимают собственные Triton-кернелы

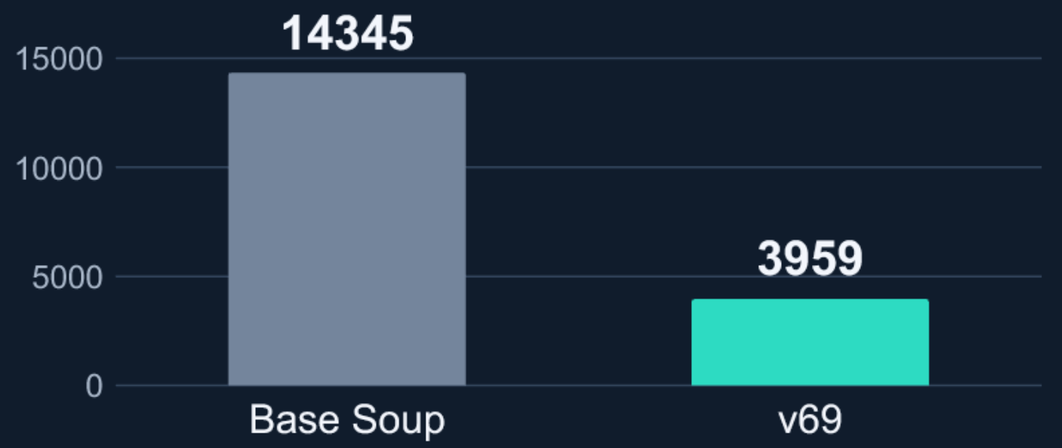
Результат полной команды

Время, с



−43,3% времени

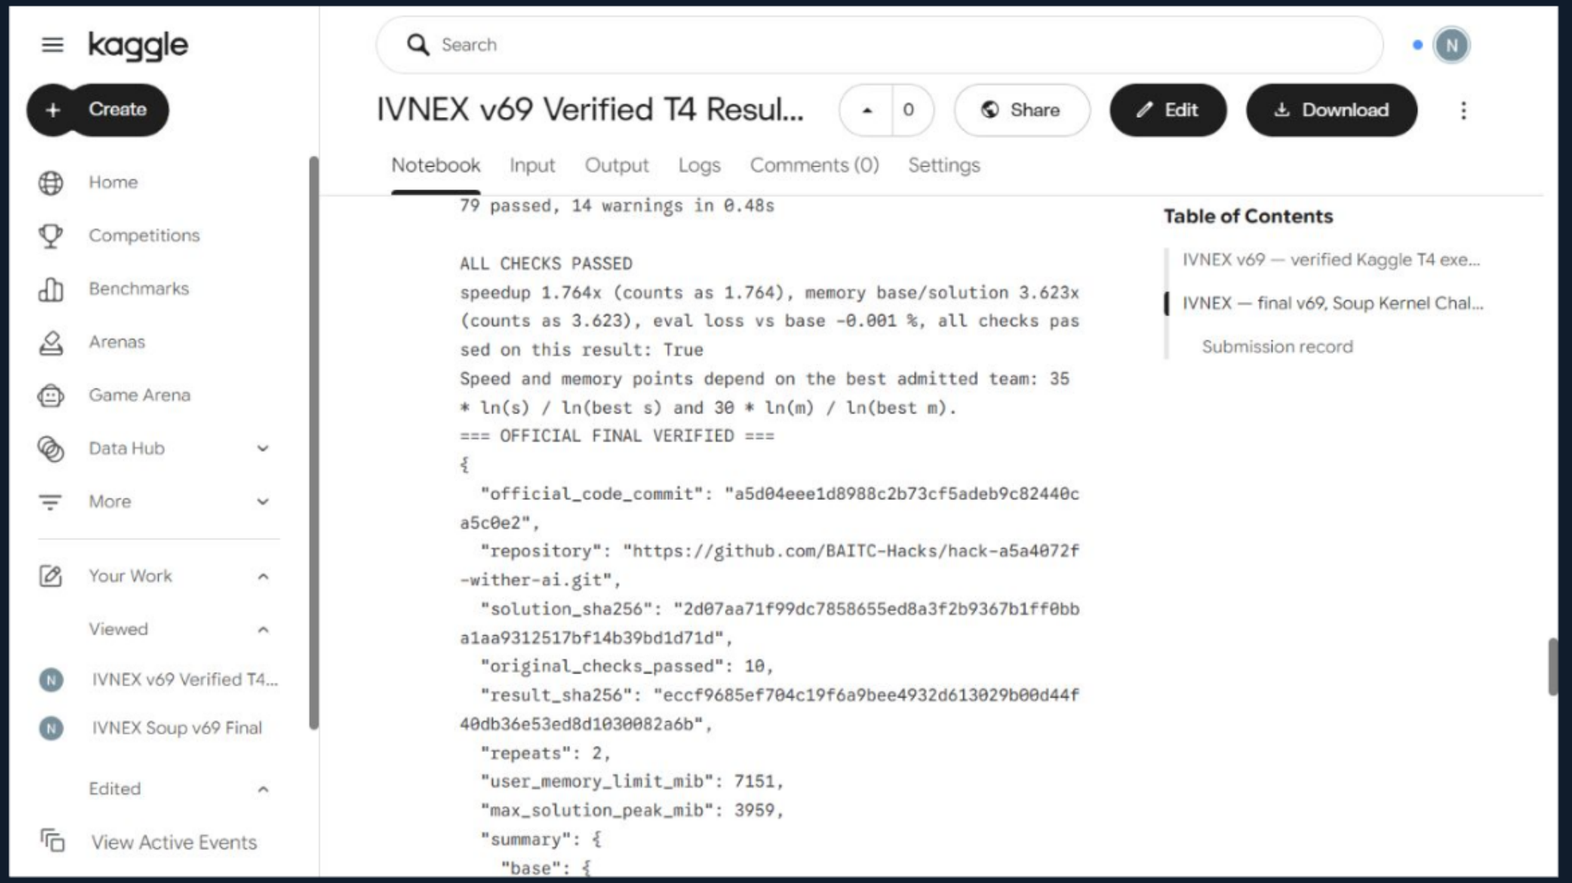
Пиковая GPU-память, MiB



−72,4% памяти

Качество	Base Soup	v69	Изменение
Eval loss	**2.04967**	**2.04964**	**−0.001%**

Проверка 10/10



10/10 PASS

79

регрессионных тестов Soup

416 PASS / 1 SKIP

тесты решения

Повторение результата

1 **Официальный репозиторий**

BAITC-Hacks/hack-a5a4072f-wither-ai

2 **Настройки Kaggle**

T4 x2, Internet On, разрешённый GITHUB_TOKEN

3 **Run All**

2 base + 2 solution, затем 10 исходных проверок

```
python harness/run_task.py --repeats 2
python harness/check_rules.py
```

Границы результата и материалы

Один воспроизводимый результат на T4

FP16 и закреплённое окружение
Скрытые строки и seed проверяет жюри
Цель 20–30 с / 500 MiB не достигнута

Код и SUBMISSION.md

Публичный Kaggle с результатами 10/10

Нұржігіт Мерей Владимир Анаис